

RDU 逐小时气温预测

方法、数据隔离、模型选择与最终结果说明

预测任务：在 2026-09-17 00:00 EDT 一次性预测到 2026-09-30 23:00 EDT，共 336 小时。最终测试集没有参与训练、预处理拟合、特征选择、调参或模型选择。

项目摘要

项目使用 Iowa Environmental Mesonet (IEM) 的真实机场站点报告替代原始的网格/再分析基线。所有模型在相同的历史预测窗口上比较，包括可解释的季节模型与异常修正、课程要求的线性回归、Ridge、梯度提升和随机森林。

- 开发数据：2015-01-01 到预测截止时刻。RDU 是预测目标，GSO 和 CLT 作为邻站候选特征。
- 清洗后数据：307,323 个站点小时；因果监督数据：453 个历史预测起点、151,960 个有真实标签的训练行。
- 模型选择：19 个预先固定的配置，在 8 个历史 14 天窗口上回测。最终测试有 336/336 个真实小时标签。
- 测试前选定的主模型：年度/日内周期参考 + 过去 72 小时温度异常，并让异常影响按 72 小时时常逐渐衰减。
- 主模型测试 RMSE 7.307°F (4.06°C)，MAE 6.097°F (3.39°C)，R² 0.492。预先保留的非线性模型 RMSE 为 6.969°F，但查看测试后没有更换主模型。

整体流程

01 获取	02 清洗	03 特征	04-05 验证选型	06 冻结	07-08 评估解释
IEM 例行报告	小时站点标签	过去状态 + 日历	8 个历史窗口	预测 + 哈希	336 标签 + 图表

1. 数据来源与预测目标

预测目标是 Raleigh-Durham International Airport (RDU) 站点报告的逐小时地面气温。数据来自公开的 IEM ASOS/METAR 档案。API 同时获取 RDU、Greensboro (GSO) 和 Charlotte (CLT) 的例行报告。变量包括气温、露点、海平面气压、风速和风向。

- 开发期：2015-01-01 到 2026-09-17 04:00 UTC，任何开发请求都不能越过该截止时间。
- 最终测试期：2026-09-17 04:00 UTC 到 2026-10-01 04:00 UTC，只能在冻结后访问。
- 只请求例行报告 report_type=3，不混合高频记录和特殊报告。
- 每个下载文件都有 JSON 来源记录，包含 URL、时间边界、下载时间、行数、观测范围和 SHA-256。

小时标签口径

分钟位于 :45 到 :59 的例行报告映射到下一个整点。如果同一站点同一小时出现多条报告，保留最后一条。实际观测时间单独保留，以便审计该信息在预测起点是否可用。因此，本项目预测的是接近前一小时末的站点报告，不是小时平均值。

历史档案没有完整保留每条记录最初发布及后续修订的时间。代码采用 15 分钟可用性缓冲作为明确假设，并在报告中保留该局限。

2. 数据清洗与质量控制

- 把所有时间解析为 UTC，并统一站点编号。
- 使用测试前固定的合理范围：气温 -60 至 130°F；露点 -80 至 100°F；气压 850 至 1100 hPa；风速 0 至 150 节；风向 0 至 360 度。
- 超出范围的字段设为缺失，但绝不伪造目标值。没有真实气温标签的行不参与训练和评分。
- 拒绝截止时刻及之后的开发标签和来源观测。截止前最后 14 天 RDU 目标覆盖率为 100%。




图 1：各站点各年份真实小时目标覆盖率。

3. 特征构建与特征选择

特征按组组织。是否保留某组特征，只能通过历史验证集比较，不能看最终测试结果。

特征组	例子	为什么预测时可用
日历	日/年正弦弦、二阶谐波、日内×年度交互	未来时间戳已知
预测时距	第几小时、log 时距、平滑衰减交互	1-336 小时时距已知
RDU 状态	24/72/168 小时异常、覆盖率、最后异常与年龄、波动和趋势	只用预测起点前观测
RDU 天气	露点差、气压及变化、风的 u/v 分量	只用过去 24-48 小时
邻站	GSO/CLT 过去 24 小时异常与覆盖率	只用过去观测

每个模拟年份都单独拟合年度周期参考，只使用该年 1 月 1 日以前、最多 8 年的数据。例如，2020 年的特征不会使用 2021-2026 年标签拟合出的季节参考。

从 2018 年开始按 7 天间隔建立历史预测起点，每个起点生成未来 336 行。描述当前天气的状态固定在起点已知值；未来只改变日历和预测时距。预测窗口内部后来发生的真实天气绝不会作为 predictor。

特征选择方法

使用验证集上的成组消融。在完全相同的 HGB 参数和验证小时上，先用本站温度状态，再加入本站气象，再加入邻站。对于 15 叶节点 HGB，加入本站气象使平均 RMSE 降低 0.367°F；再加入邻站降低 0.030°F，并在 8 折中的 6 折改善。提升较小，因此只把邻站版本保留为非线性对照，不做因果解释。




图 2：只使用历史验证集的特征组消融；负数表示误差下降。

4. 候选模型与选择规则

模型族	配置	用途
基线	季节气候均值; 重复前一天	最低比较标准
OLS	基础周期; 周期+谐波/交互	课程要求且容易解释
Ridge	alpha 10/1000; 有/无趋势	正则化线性模型
异常修正	衰减时常 24/72/168 小时	季节参考 + 最近偏离
Direct Ridge	状态×预测时距衰减交互	线性多步残差模型
HGB	7/15 叶 × 状态/气象/邻站	小型非线性残差树
随机森林	100 棵树, 限制深度和叶节点	额外树模型对照

8 个验证起点为: 2021/2022/2023 年 9 月 17 日; 2024/2025 年 8 月 15 日和 9 月 17 日; 2026 年 8 月 15 日。每一折都从当地零点一次性预测完整 336 小时, 不接收新的真实观测。

只有当一个训练起点的整个 336 小时目标窗口都结束于验证起点以前, 该训练样本才可使用。imputer 和 scaler 都只在本折训练数据上 fit。HGB 关闭随机 early stopping, 避免库内部产生未经控制的随机验证切分。

预先固定的选择规则: 先找平均折 RMSE 最低值; 在最低值 1% 以内, 优先选复杂度更低的模型; 如果复杂度仍相同, 再选 RMSE 更低者。OLS 和验证期最好的非线性模型另外保留作比较。




图 3: 8 个历史 14 天窗口的平均 RMSE; 误差棒为窗口间标准差。

5. 冻结流程与测试集隔离

流程同时使用目录隔离、程序检查和文件哈希，避免最终测试成绩反过来影响建模选择。

- 开发阶段只读取 data/development；只有 step 07 可以访问 data/test_locked。
- API 请求层先拒绝跨越截止点的开发请求；读取数据时再次检查时间边界。
- 访问 test 前，step 06 只拟合已经选定的最终模型，保存 336 行预测、模型、特征、线性系数和基于验证残差的区间规则。
- freeze manifest 保存源代码、开发数据、模型和预测的哈希。任何冻结文件变化，step 07 都会拒绝运行。
- 一旦开始访问测试数据，就写入永久锁；之后开发入口拒绝重新训练或重新选择。
- 最终评估不导入训练/选型函数，审计记录为 0 次 fit、0 次特征选择、0 次模型选择。
- 9 个合成数据测试检查严格截止、请求保护、访问锁、整段窗口清除、不填造标签，以及未来数据投毒不能改变特征或拟合结果。

6. 指标如何计算

指标	计算	含义
RMSE	$\sqrt{\text{mean}((\text{预测}-\text{真实})^2)}$	对大误差惩罚更重；主要选择指标
MAE	$\text{mean}(\text{abs}(\text{预测}-\text{真实}))$	典型绝对误差，单位 °F
Bias	$\text{mean}(\text{预测}-\text{真实})$	正数表示平均预测偏热
R ²	$1 - \text{SSE}/\text{SST}$	相对测试均值解释的波动比例
±2°C 内比例	绝对误差 ≤ 3.6°F 的比例	评分后补充的描述性容差指标

这是回归问题，R² 和容差比例都不等于分类 accuracy。如果测试标签缺失，会排除该小时并报告覆盖率，绝不会插值出假的真实值。本次 336 个小时全部有标签。

7. 最终结果

模型	测试前确定的角色	回测 RMSE °F	测试 RMSE °F	测试 MAE °F	测试 R²	±2°C 内
anomaly_tau72	预选主模型	5.768	7.307	6.097	0.492	32.14%
ols_harmonics	课程要求 OLS	5.863	7.653	6.398	0.443	31.85%
ridge_a1000_trend0	最佳 Ridge	5.854	7.669	6.423	0.440	31.25%
hgb_neighbors_l15	非线性对照	5.879	6.969	5.298	0.538	46.13%
baseline_climatology	季节基线	5.855	7.654	6.317	0.443	33.33%
baseline_yesterday	持久性基线	8.202	8.745	7.057	0.272	25.60%

主模型在读取最终测试前已经选定。其测试 RMSE 为 7.307°F (4.06°C) ， MAE 为 6.097°F (3.39°C) ， R² 为 0.492。Bias 为 -0.272°F，平均冷暖偏差很小，但逐小时误差仍然明显。

预先保留的 HGB 对照模型测试 RMSE 更低，为 6.969°F，R² 更高，为 0.538。因为这一点只是在打开 test 后才知道，所以不能回头把它提升为主模型。未来可以把它作为下一轮候选，但必须使用另一个从未查看的最终测试期。

历史验证残差构造的名义 80% 区间，在最终测试上实际只覆盖 64.58%。因此该区间校准不足，不能声称具有严格 80% 覆盖保证。




图 4：冻结预测与最终未见观测值对比。

8. 解释、局限与 Git 交接

为什么选择简单模型

在历史验证中，`anomaly_tau72` 的平均 RMSE

最低 (5.768°F)，而且容易解释：先得到季节和小时参考，再判断过去三天比正常偏热还是偏冷，让修正逐步衰减。HGB 验证 RMSE 为 5.879°F，接近但更复杂，因此固定的 1% 规则选择 `anomaly` 模型。

主要局限

- 仅靠站点历史无法提前知道未来冷锋、降水、云量和大尺度环流；14 天预测的信息上限明显。
- 历史验证窗口数量有限且参与了模型选择，不能把其成绩当作完全独立的性能估计。
- IEM 档案可能包含事后修订，15 分钟可用性缓冲只是明确假设。
- 特征消融和线性系数只能解释模型行为，不能证明气象因果关系。
- 最终测试结果已经公开；任何根据它做出的修改，都必须用新的未见时期重新做最终评估。

队友应该查看什么

- 仓库入口：README.md；完整方法：`rdu_forecast/README.md`；通俗代码导读：`rdu_forecast/CODE_GUIDE.md`。
- 在 `rdu_forecast` 中运行 `python tools/09_verify_delivery.py`，无需训练即可核对冻结链和重新计算分数。
- 在 `reference_results/artifacts/results.html` 查看全部结果和图片。当前分支为 `codex/rdu-station-forecast`，可通过 Pull Request 合入 `main`。

参考资料

Iowa Environmental Mesonet ASOS/METAR archive: <https://mesonet.agron.iastate.edu/request/download.phtml>

Scikit-learn lagged-feature example: https://scikit-learn.org/stable/auto_examples/applications/plot_time_series_lagged_features.html

Zeng et al., Are Transformers Effective for Time Series Forecasting?: <https://arxiv.org/abs/2205.13504>

Lou et al., Accurate Intelligible Models with Pairwise Interactions: <https://www.cs.cornell.edu/~yinlou/papers/lou-kdd13.pdf>